





Types arithmétiques et conversions



- Entiers signés
 - Représentation en mémoire
 - `numeric_limits`
 - Dépassement
- Entiers non signés
- Alias de type et entiers de taille fixe
- Entiers littéraux
- Entrées / sorties entières





- Stockés en mémoire sous forme binaire
 - **Bit** = chiffre binaire : 0 ou 1
 - **Octet** = groupe de 8 bits
 - **Byte** = plus petit groupe de bits adressable. Typiquement un octet, mais pas toujours. Le nombre exact est défini dans la constante `CHAR_BIT` provenant de `<climits>`.
- Le **nombre de bits utilisés** détermine le nombre d'entiers représentables
 - Avec n bits - $\frac{n}{8}$ octets - on peut représenter jusqu'à 2^n entiers différents
 - Les entiers positifs de 0 à $2^{n-1} - 1$ sont codés en base 2. Leur premier bit est toujours 0
 - Pour les entiers négatifs, cela dépend de leur représentation, qui n'est pas spécifiée par le standard C++. Leur premier bit est toujours 1.

Entier	Binaire	Hexadécimal
1	0000000000000001	0001
2	0000000000000010	0002
3	0000000000000011	0003
16	00000000000010000	0010
127	0000000001111111	007F
255	000000011111111	00FF
256	000000100000000	0100
32767	011111111111111	7FFF



- Même si ce n'est pas obligatoire, tous les systèmes actuels utilisent le complément à 2 pour représenter les entiers négatifs
 - Coder la valeur absolue en base 2
 - Inverser tous les bits (0 devient 1, 1 devient 0)
 - Ajouter 1
- En complément à 2 avec des entiers sur n bits, on peut coder les entiers négatifs de -2^{n-1} à -1

Note : les autres représentations diffèrent peu. Par exemple, une représentation signe + amplitude peut coder les entiers de $-(2^{n-1} - 1)$ à $2^{n-1} - 1$. L'entier 0 utilise alors 2 représentations binaires



Complément à 2 : entiers négatifs sur 16 bits

Entier	Binaire	Hexadécimal
-1	1111111111111111	FFFF
-2	1111111111111110	FFFE
-3	1111111111111101	FFFD
-4	1111111111111100	FFFC
-16	1111111111111000	FFF0
-255	11111111100000001	FF01
-256	11111111100000000	FF00
-32768	10000000000000000	8000

HE^{VD} IG Types entiers signés en C++



- Le C++ propose 4 tailles d'entiers signés

`signed short int`

`signed int`

`signed long int`

`signed long long int`

- Les mots clés `signed` et `int` sont optionnels. L'ordre des éléments du type n'est pas fixé. `long long`, `long int long`, et `long long signed` par exemple sont des noms de type valables, synonymes de `signed long long int`
- La nombre de bits utilisés par ces types n'est pas garanti. Les seules garanties sont
 - `sizeof(short) <= sizeof(int) <= sizeof(long) <= sizeof(long long)`
 - `short` et `int` utilisent au moins 16 bits, `long` au moins 32, et `long long` au moins 64
- On peut également utiliser le type caractère `signed char` comme un entier sur 8 bits. Le mot clé `signed` n'est pas optionnel dans ce cas



- L'opérateur `sizeof` retourne le nombre de **bytes** utilisés par le type ou l'expression en paramètre

- Syntaxe :

`sizeof(type)`

`sizeof expression`

- Utilisation :

```
cout << "s char      : " << sizeof(signed char) << endl;
cout << "short       : " << sizeof(short)         << endl;
cout << "int          : " << sizeof(int)           << endl;
cout << "long         : " << sizeof(long)          << endl;
cout << "long long    : " << sizeof(long long)      << endl;
short int a = 42;
cout << "a           : " << sizeof a               << endl;
```

s char	:	1
short	:	2
int	:	4
long	:	8
long long	:	8
a	:	2



Nombre de bits des types entiers

- En combinant `sizeof` et `CHAR_BIT`, on peut déterminer la taille en bits des types entiers


```
cout << "short      : " << sizeof(short) * CHAR_BIT << endl;  
cout << "int        : " << sizeof(int) * CHAR_BIT << endl;  
cout << "long       : " << sizeof(long) * CHAR_BIT << endl;  
cout << "long long  : " << sizeof(long long) * CHAR_BIT << endl;
```

- Le résultat peut varier selon l'architecture cible. Par exemple, pour des systèmes 64 bits.



short	:	16
int	:	32
long	:	32
long long	:	64

short	:	16
int	:	32
long	:	64
long long	:	64





4 modèles de données sont / ont été largement utilisés. Ils sont caractérisés par 3 chiffres : les nombres de bytes utilisés par les types `int` / `long` / pointeur

- **LP32** ou **2/4/4** - `int` 16-bit, `long` et pointeurs 32-bit : Win16 API
- **ILP32** ou **4/4/4** - `int`, `long`, et pointeurs 32-bit : Win32 API, Unix, Linux, macOS sur systèmes 32 bits
- **LLP64** ou **4/4/8** - `int` et `long` 32-bit, pointeurs 64-bit : Windows API pour systèmes x64 ou ARM64
- **LP64** ou **4/8/8** - `int` 32-bit, `long` et pointeurs 64-bit : Unix, Linux, macOS sur systèmes 64 bits

D'autres modèles existent mais sont très rares. Par exemple, **ILP64** ou **8/8/8** - `int`, `long`, et pointeurs 64-bit : UNICOS (super-ordinateurs Cray)



- La manière la plus propre de connaître les propriétés d'un type numérique est d'utiliser les méthodes de `std::numeric_limits` , provenant de la librairie `<limits>`
- Syntaxe :
 - `std::numeric_limits<type>::lowest()` // plus petite valeur représentable
 - `std::numeric_limits<type>::max()` // plus grande valeur représentable
 - `std::numeric_limits<type>::digits` // nombre de bits hors bit de signe
 - `std::numeric_limits<type>::is_signed` // vrai pour les types signés
 - `std::numeric_limits<type>::is_integer` // vrai pour les types entiers

HE^{VD}IG numeric_limits : utilisation

```
#include <iostream>
using namespace std;

int main() {
    cout << " ** signed short int ** " << endl;
    cout << "lowest : " << std::numeric_limits<short>::lowest
    cout << "max      : " << std::numeric_limits<short>::max()
    cout << "digits : " << std::numeric_limits<short>::digits

    cout << "\n ** signed int ** " << endl;
    cout << "lowest : " << std::numeric_limits<int>::lowest() << endl;
    cout << "max      : " << std::numeric_limits<int>::max() << endl;
    cout << "digits : " << std::numeric_limits<int>::digits << endl;

    cout << "\n ** signed long long int ** " << endl;
    cout << "lowest : " << std::numeric_limits<long long>::lowest() << endl;
    cout << "max      : " << std::numeric_limits<long long>::max() << endl;
    cout << "digits : " << std::numeric_limits<long long>::digits << endl;
}
```

```
    ** signed short int **
lowest : -32768
max      : 32767
digits : 15

    ** signed int **
lowest : -2147483648
max      : 2147483647
digits : 31

    ** signed long long int **
lowest : -9223372036854775808
max      : 9223372036854775807
digits : 63
```



- Le résultat d'un calcul effectué avec un type donné peut ne pas être représentable dans ce type. On parle de dépassement
- Exemple avec `std::numeric_limits<int>::max()` qui vaut 2'147'483'647 :

```
int a = 2'000'000'000;  
int b = 1'000'000'000;  
int c = a + b;  
cout << a << " + " << b << " = "  
      << c << endl;
```

2000000000 + 1000000000 = -1294967296

- Selon le standard C++, un dépassement sur un calcul en type entier signé donne un résultat **non défini**, et donc inutilisable



Comportement indéfini ?

- En pratique, en complément à 2, il est très probable que

```
cout << numeric_limits<int>::max() + 1;
```

affiche

-2147483648

- Attention, on ne peut pas s'y fier ! Par exemple, le code suivant

```
int x = numeric_limits<int>::max();  
cout << boolalpha << ( x < x + 1 ) << endl;
```

- compilé en mode debug, affiche
- compilé en mode release, affiche

false

true

- En effet, $x < x + 1$ est vrai pour tout x sauf en cas de dépassement qui - n'étant pas défini pour x entier signé - peut être ignoré par l'optimisation

HE^{VD} IG Prévenir un dépassement



- On peut vérifier si un calcul va dépasser avant de l'effectuer
- L'addition déborde si
 - Les 2 opérandes sont positives et le résultat est $> \text{numeric_limits}\langle\text{int}\rangle::\text{max}()$
 - Les 2 opérandes sont négatives et le résultat est $< \text{numeric_limits}\langle\text{int}\rangle::\text{lowest}()$
- Le code suivant vérifie ces deux possibilités


```
bool sum_would_overflow(int lhs, int rhs) {  
    return (lhs >= 0) ?  
           numeric_limits<int>::max() - lhs < rhs :  
           rhs < numeric_limits<int>::lowest() - lhs;  
}
```

- Soustraction et multiplication peuvent également déborder

HE^{VD} IG Vol 501 d'Ariane 5



- Vol inaugural, 4 juin 1996
- Même système de guidage inertiel qu'Ariane 4
- Accélérations 5 fois plus fortes qu'Ariane 4
- Dépassement dans le calcul de la position à partir des accélérations
- L'ordinateur de bord ordonne un virage serré pour corriger la trajectoire
- L'accélération latérale arrache un des boosters latéraux
- La destruction automatique est engagée 😞



HE^{VD} IG Entiers non signés



- A chacun des types d'entier signé correspond un type d'entier non signé de même taille en remplaçant le mot clé `signed` par `unsigned`

`unsigned char`

`unsigned short int`

`unsigned int`

`unsigned long int`

`unsigned long long int`

- Le mot clé `int` est optionnel. L'ordre des éléments du type n'est pas fixé. `long unsigned int long` est un nom de type valable, synonyme de `unsigned long long int`
- Un type `unsigned` de n bits peut représenter les entiers positifs de 0 à $2^n - 1$
- En mémoire, les bits correspondent à la représentation de l'entier en base 2



Limites typiques des entiers non signés

```
cout << "unsigned char      ( " << std::numeric_limits<unsigned char>::digits << " bits ) : "
<< +std::numeric_limits<unsigned char>::lowest() << " -> "
<< +std::numeric_limits<unsigned char>::max() << endl;

cout << "unsigned short     ( " << std::numeric_limits<unsigned short>::digits << " bits ) : "
<< std::numeric_limits<unsigned short>::lowest() << " -> "
<< std::numeric_limits<unsigned short>::max() << endl;

cout << "unsigned int        ( " << std::numeric_limits<unsigned>::digits << " bits ) : "
<< std::numeric_limits<unsigned>::lowest() << " -> "
<< std::numeric_limits<unsigned>::max() << endl;

cout << "unsigned long long ( " << std::numeric_limits<unsigned long long>::digits << " bits ) : "
<< std::numeric_limits<unsigned long long>::lowest() << " -> "
<< std::numeric_limits<unsigned long long>::max() << endl;
```

unsigned char	(8 bits)	:	0 -> 255
unsigned short	(16 bits)	:	0 -> 65535
unsigned int	(32 bits)	:	0 -> 4294967295
unsigned long long	(64 bits)	:	0 -> 18446744073709551615



Arithmétique modulo 2^n

- Il n'y a **pas de dépassement** dans les calculs effectués en unsigned
- Les opérateurs +, -, et * sont définis « modulo 2^n »

```
unsigned a32 = 2'000'000'000, b32 = 3'000'000'000;  
unsigned long long a64 = a32, b64 = b32;  
cout << a32 << " + " << b32 << " = " << a32 + b32  
      << " = " << a64 + b64 << " mod 4294967296";
```

$2000000000 + 3000000000 = 705032704 = 5000000000 \bmod 4294967296$

- En pratique, aucun calcul de modulo n'est effectué par le processeur. Il se contente d'ignorer les bits de report au-delà du $n^{\text{ième}}$ bit lors des calculs.
- L'unsigned le plus grand et 0 sont des entiers consécutifs

```
unsigned zero = 0; cout << zero - 1 << endl;  
cout << numeric_limits<unsigned>::max() + 1 << endl;
```

4294967295 0



- Le spécificateur typedef permet de définir des **alias de type**, i.e. de nouveaux noms de types synonymes de types existants

- Syntaxe :

```
typedef type_existant nouveau_type;
```

- Exemple :

```
typedef int Entier;  
Entier entier = 42;  
  
typedef double Reel;  
Reel pi = 3.141592;
```



- Le spécificateur `using` permet une syntaxe alternative à `typedef`
- Syntaxe :

```
using nouveau_type = type_existant;
```

- Exemple :

```
using Entier = int;  
Entier entier = 42;  
  
using Reel = double;  
Reel pi = 3.141592;
```

- Cette syntaxe est préférable en C++ moderne, `typedef` étant un reliquat du langage C



Entiers signés de taille fixe de `<cstdint>`

- Le header `<cstdint>` fournit les alias de type suivants

<code>int8_t</code>	• Entier signé dont la taille est exactement 8, 16, 32, 64 bits.
<code>int16_t</code>	• Utilisent le complément à 2 pour les entiers négatifs
<code>int32_t</code>	• Potentiellement non définis si aucun type parmi <code>signed char</code> , <code>short</code> , <code>int</code> , <code>long</code> et <code>long long</code> ne respecte ces contraintes
<code>int64_t</code>	
<code>int_fast8_t</code>	• Entier signé dont la taille est au moins 8, 16, 32, 64 bits.
<code>int_fast16_t</code>	• Le type le plus rapide à l'exécution respectant cette contrainte
<code>int_fast32_t</code>	
<code>int_fast64_t</code>	
<code>int_least8_t</code>	• Entier signé dont la taille est au moins 8, 16, 32, 64 bits.
<code>int_least16_t</code>	• Le type le plus petit respectant cette contrainte
<code>int_least32_t</code>	
<code>int_least64_t</code>	
<code>intmax_t</code>	• Entier signé dont la taille est la plus grande possible
<code>intptr_t</code>	• Entier signé dont la taille permet de stocker un pointeur
	• Potentiellement non défini si aucun type existant ne respecte cette contrainte



Entiers non signés de taille fixe

- Le header `<cstdint>` fournit les alias de type suivants pour les types non signés

<code>uint8_t</code>	• Entier non signé dont la taille est exactement 8, 16, 32, 64 bits.
<code>uint16_t</code>	• Potentiellement non définis si aucun type parmi <code>unsigned char</code> , <code>unsigned short</code> , <code>unsigned int</code> , <code>unsigned long</code> et <code>unsigned long long</code> ne respecte ces contraintes
<code>uint32_t</code>	
<code>uint64_t</code>	
<code>uint_fast8_t</code>	• Entier non signé dont la taille est au moins 8, 16, 32, 64 bits.
<code>uint_fast16_t</code>	• Le type le plus rapide à l'exécution respectant cette contrainte
<code>uint_fast32_t</code>	
<code>uint_fast64_t</code>	
<code>uint_least8_t</code>	• Entier non signé dont la taille est au moins 8, 16, 32, 64 bits.
<code>uint_least16_t</code>	• Le type le plus petit respectant cette contrainte
<code>uint_least32_t</code>	
<code>uint_least64_t</code>	
<code>uintmax_t</code>	• Entier non signé dont la taille est la plus grande possible
<code>uintptr_t</code>	• Entier non signé dont la taille permet de stocker un pointeur
	• Potentiellement non défini si aucun type existant ne respecte cette contrainte



- Type de retour de l'opérateur **sizeof**
- Alias d'un type **entier non signé** suffisamment grand pour **stocker la taille** de tout objet en C++ y compris des tableaux
- Défini dans de nombreux headers : `<cstddef>`, `<cstdio>`, `<cstdlib>`, ...
- Peut-être synonyme de `unsigned int` (e.g. win32), `unsigned long` (e.g. macOS) ou `unsigned long long` (e.g. win64)
- Type des **indices** pour accéder aux éléments d'un `std::array`, d'un `std::vector`, ou aux caractères d'une `std::string`



- Les entiers littéraux permettent d'écrire une valeur entière dans le code. Ils sont constitués, sans caractère blanc intercalaire, de
 - Un **préfixe** optionnel spécifiant la base (2, 8, 10 ou 16)
 - Une suite de **chiffres** dans cette base (0 ou 1 en binaire, 0 à 7 en octal, 0 à 9 en décimal, 0 à F en hexadécimal, casse au choix pour les chiffres A à F)
 - Un **suffixe** optionnel spécifiant le type (`signed` / `unsigned` et `int` / `long` / `long long`)
 - On peut intercaler le caractère ' entre les chiffres. Il ne change pas la valeur mais peut aider à rendre la valeur numérique plus lisible
- Exemples :

```
int un_million = 1'000'000;  
long vingt_six = 032L;  
unsigned long long quarante_deux = 0x00'00'00'2Aull;
```



Préfixe de base

- Les entiers littéraux peuvent être précédés d'un préfixe qui spécifie la base

0b ou 0B	Binaire (2)
0	Octal (8)
Pas de préfixe	Décimal (10)
0x ou 0X	Hexadécimal (16)

- Exemple :

```
cout << 0b10 << ' ' << 010 << ' ' << 10 << ' ' << 0x10 << endl;
```

```
cout << 0b101010 << ' ' << 052 << ' ' << 42 << ' ' << 0x2A ' ' << 0x2a ;
```

2	8	10	16	
42	42	42	42	42

HE^{VD} IG Suffixes de type



- Les entiers littéraux peuvent être suivis d'un suffixe qui spécifie le type

Pas de suffixe	<code>signed int</code>
L	<code>signed long int</code>
LL	<code>signed long long int</code>
U	<code>unsigned int</code>
UL	<code>unsigned long int</code>
ULL	<code>unsigned long long int</code>

- Minuscule ou majuscule à choix
- Ordre quelconque entre U et L / LL. Ainsi, `u11`, `uLL`, `11u`, `LLu`, `U11`, `ULL`, `11U`, et `LLU` sont des suffixes valides pour `unsigned long long`

Note : C++23 introduit le suffixe UZ pour le type `size_t`

HE^{VD} IG Autres suffixes de type



Note : Les suffixes de type sont également utilisés dans la STL. Par exemple, la librairie <chrono> définit les suffixes ns, us, ms, s, min, et h.

Ils spécifient non seulement le type mais aussi comment interpréter la valeur numérique qui les précède

```
chrono::duration seconde = 1'000'000'000ns;  
seconde = 1'000'000us;  
seconde = 1'000ms;  
chrono::duration minute = 60s;  
chrono::duration heure = 60min;  
chrono::duration jour = 24h;
```

HE^{VD} IG Type d'un entier littéral



- Le suffixe de type (ou son absence) ne spécifie que la taille minimale du type de l'entier.
- Si l'entier littéral est trop grand par rapport à ce type, le plus petit type capable de le contenir sera sélectionné.
- Exemples (en supposant que le type long utilise 64 bits) :

```
auto a = 1'000'000'000;      // int
auto b = 5'000'000'000;      // long
auto c = 0x123456789ABCDEF0; // long
auto d = 0xFEDCBA9876543210; // unsigned long

// auto e = 10'000'000'000'000'000'000'000'000;
// ne compile pas, la valeur littérale étant trop
// grande être représentable dans tout type entier.
```

HE^{VD} IG Affichage des entiers



- `<iomanip>` fournit divers **modificateurs de flux** dédiés à l'affichage d'entiers
 - `oct`, `dec`, `hex` spécifient la base octale, décimale ou hexadécimale
 - `setbase(n)` avec `n = 8`, `10`, ou `16` fait de même. Toute autre valeur de `n` rétablit l'affichage par défaut (décimal)
 - `showbase` ajoute `0` / `0x` devant les chiffres lors de l'affichage en octal / hexadécimal. `noshowbase` (par défaut) l'annule.
 - `uppercase` affiche les chiffres hexadécimaux A à F en majuscule. `nouppercase` (par défaut) les affiche en minuscule
 - `showpos` ajoute le signe `+` devant les entiers positifs affichés en décimal. `noshowpos` (par défaut) l'annule
- Les modificateurs de flux spécifiant la base (`oct`, `dec`, `hex`, et `setbase(n)`) fonctionnent également pour la **lecture** d'entiers



Affichage en décimal

- Affichage par défaut, ou via les modificateurs **dec** ou **setbase(n)** avec n différent de 8 ou 16.
- **showbase**, **noshowbase**, **uppercase**, et **nouppercase** n'ont pas d'effet
- **showpos** ajoute le symbole + devant les entiers positifs, **noshowpos** (par défaut) le supprime

```
cout << 42 << " " << -42 << endl;  
cout << showpos;  
cout << 42 << " " << -42 << endl;  
cout << noshowpos;  
cout << 42 << " " << -42 << endl;  
cout << hex << showbase << 42 << " ";  
cout << dec << -42 << endl;
```

```
42 -42  
+42 -42  
42 -42  
0x2a -42
```



Affichage en octal

- Affichage via les modificateurs **oct** ou **setbase(8)**
- **showbase** ajoute le symbole 0 devant les chiffres, **noshowbase** (par défaut) le supprime
- Pour les entiers négatifs, c'est leur motif binaire en mémoire qui est affiché, pas leur valeur signée.
- **showpos**, **noshowpos**, **uppercase** et **nouppercase** n'ont pas d'effet

```
cout << 42 << " " << -42 << endl;  
cout << oct;  
cout << 42 << " " << -42 << endl;  
cout << showbase;  
cout << 42 << " " << -42 << endl;  
cout << noshowbase;  
cout << 42 << " " << -42 << endl;
```

```
42  -42  
52  37777777726  
052  037777777726  
52  37777777726
```



Affichage en hexadécimal

- Affichage via les modificateurs **hex** ou **setbase(16)**
- **showbase** ajoute les symboles 0x devant les chiffres, **noshowbase** (par défaut) les supprime
- **uppercase** et **nouppercase** changent la casse des chiffres A à F
- Pour les entiers négatifs, c'est leur motif binaire en mémoire qui est affiché, pas leur valeur signée
- **showpos**, et **noshowpos** n'ont pas d'effet

```
cout << 42 << " " << -42 << endl;  
cout << hex;  
cout << 42 << " " << -42 << endl;  
cout << showbase;  
cout << 42 << " " << -42 << endl;  
cout << uppercase;  
cout << 42 << " " << -42 << endl;  
cout << noshowbase << nouppercase;  
cout << 42 << " " << -42 << endl;
```

```
42  -42  
2a  ffffffff d6  
0x2a  0xffffffff d6  
0X2A  0XFFFFFFFF D6  
2a  ffffffff d6
```



- **setbase(n)**, **oct**, **hex**, et **dec** affectent la manière dont le flux d'entrée est interprété lors de la lecture d'une variable entière
 - **dec** ou **setbase(10)** : par défaut, entrée décimale
 - **oct** ou **setbase(8)** : entrée octale
 - **hex** ou **setbase(16)** : entrée hexadécimale
- Dans ces bases, le symbole **-** est interprété comme un nombre négatif, le symbole **+** (optionnel) comme positif. Le préfixe de cette base est le seul reconnu. La lecture s'arrête au premier caractère qui n'est pas un chiffre de la base choisie.
- **setbase(0)** ou tout autre valeur différente de 8, 10 ou 16 : prise en compte des préfixes **0** ou **0x** ou de leur absence pour déterminer la base. Le nombre lu doit être suivi d'un caractère blanc




```
int e; cin >> setbase(n) >> e;
```

Valeur de n	Entrée utilisateur	Valeur de e
10	-10a	-10
	+010a	10
	0x10	0
8	-10a	-8
	+010a	8
	0x10	0
16	-10a	-266
	+010a	266
	0x10	16
0	-10	-10
	+010	8
	0x10	16
	10a	0

Réels

- Représentation en mémoire : IEEE 754, zéro, nombres dénormalisés, infini, NaN.
- Types réels en C++ : float, double, long double
- `std::numeric_limits` : `radix`, `digits`, `min()`, `denorm_min()`, `lowest()`, `max()`, `epsilon()`, `digits10`, `max_digits10`
- Entrées / sorties réelles : `fixed`, `scientific`, `defaultfloat`, `hexfloat`, `showpoint`, `setprecision(n)`
- Réels littéraux
- `<cmath>`





- Le concept de **virgule flottante** permet de représenter de **manière approchée** une large plage de nombres réels
- Il consiste à représenter le réel r sous la forme $r = (-1)^s \cdot m \cdot b^e$, avec
 - b la **base** entière, typiquement 2 ou 10
 - s le **signe** binaire $\in \{0,1\}$
 - e l'**exposant** entier
 - m la **mantisse** réelle, avec $1 \leq m < b$ dans sa forme normalisée pour qu'une seule paire (m, e) code le même r .
- Par exemple, le réel $r = 314,2$ peut être représenté comme
 - $r = + 3,142 \cdot 10^2$ en base $b = 10$
 - $r = + 1,22734375 \cdot 2^8$ en base $b = 2$



Représentation binaire du type flottant

- Pour stocker $r = (-1)^s \cdot m \cdot b^e$ sous forme binaire, on le code en l'approximant uniquement avec des **entiers positifs**

- s est un entier sur 1 bit $\in \{0,1\}$

- e via un entier positif E dont on soustrait un biais constant B

$$e = E - B$$

$$E = e + B$$

- m via un entier positif M avec p chiffres en base b , i.e. $0 \leq M < b^p$

$$m \approx \frac{M}{b^{p-1}} < b$$

$$M = m \cdot b^{p-1}$$

- $(-1)^s \cdot M \cdot b^{E-B-p+1}$ est une **approximation** de la valeur de r . Avec p chiffres en base b pour coder la mantisse, il peut y avoir une **erreur relative** entre la valeur codée et le réel r de l'ordre de $\epsilon = \frac{1}{b^{p-1}}$



IEEE 754 : IEEE Standard for Floating-Point Arithmetic

- Etabli et mis à jour depuis 1985 par l'IEEE : Institute of Electrical and Electronics Engineers
- Définit les standards d'arithmétique en virgule flottante `binary16`, `binary32`, `binary64`, `binary128`, `decimal32`, `decimal64`, et `decimal128`
- Chacun de ces standards spécifie notamment
 - La base b : 2 ou 10
 - Le nombre de bits utilisés en tout : 16, 32, 64, 128, ou 256
 - La précision p de chiffres en base b utilisés par la mantisse entière M
 - La manière de coder les chiffres décimaux en bits pour les standards `decimal`...
 - Le biais B et donc la plage d'exposants e utilisables avec les bits restants



Exemple : $r = 42.42$ en IEEE 754 binary32

- Mantisse avec précision $p = 24$ bits codée sur 23 bits, le premier valant toujours 1 quand la mantisse est normalisée : $1 \leq m < 2$, donc $2^{23} \leq M < 2^{24}$ et on code $0 \leq M - 2^{23} < 2^{23}$
- Exposant codé sur 8 bits, moins le biais $B = 127$
- $42.42 \approx +1 \cdot 2^{132-127} \cdot (1 + \frac{2731540}{2^{23}})$

<https://www.h-schmidt.net/FloatConverter/IEEE754.html>

IEEE 754 Converter (JavaScript), V0.22

	Sign	Exponent	Mantissa
Value:	+1	2^5	1.325624942779541
Encoded as:	0	132	2731540
Binary:	☐	☒ ☐ ☐ ☐ ☐ ☒ ☐ ☐	☐ ☒ ☐ ☒ ☐ ☐ ☒ ☒ ☐ ☒ ☐ ☒ ☒ ☒ ☐ ☐ ☐ ☐ ☒ ☐ ☒ ☐ ☐

You entered	42.42	+1 -1
Value actually stored in float:	42.4199981689453125	
Error due to conversion:	-0.0000018310546875	
Binary Representation	01000010001010011010111000010100	
Hexadecimal Representation	0x4229ae14	



Zéro et les nombres dénormalisés

- La formule $r = (-1)^s \cdot m \cdot b^e$ ne permet pas trouver une mantisse $1 \leq m < b$ normalisée pour $r = 0$
- Par convention, pour le plus petit exposant e , i.e. pour $E = 0$, la mantisse est non normalisée, son premier bit ne vaut pas implicitement 1, et $r = (-1)^s \cdot M \cdot b^{1-B-p+1}$
- Le réel $r = 0$ est codé par $E = 0$ et $M = 0$. Le signe peut varier. +0 et -0 sont des nombres différents (en représentation binaire) mais égaux (en valeur)

```
double r = 0.;  
cout << r << endl;  
  
r *= -1.;  
cout << r << endl;  
  
cout << boolalpha << ( 0. == -0. ) << endl;
```

0
-0
true



- A l'opposé, le plus grand exposant e ($E_{max} = 2^q - 1$ s'il est codé sur q bits) et $M = 0$ est utilisé pour coder une valeur **infinie**, qui peut être positive ou négative selon le bit de signe.
- Divers calculs peuvent donner un résultat infini

```
cout << 1./0. << endl;  
cout << log(0.) << endl;
```

```
inf  
-inf
```

- Les types C++ supportant cette notion d'infini ont

```
numeric_limits<type>::has_infinity == true
```

- On peut directement accéder à la valeur infinie via

```
cout << numeric_limits<type>::infinity();
```

```
inf
```

HE^{VD} IG NaN : not a number



- Enfin, le plus grand exposant e et $M \neq 0$ codent « **not a number** », qui correspond au résultat de calculs impossibles ou indéterminés en nombres réels

```
cout << 0./0. << endl;  
cout << sqrt(-1) << endl;  
cout << 1./0. - 1./0. << endl;
```

```
nan  
nan  
nan
```

- Les types C++ supportant NaN ont

```
numeric_limits<type>::has_quiet_NaN == true  
numeric_limits<type>::has_signaling_NaN == true
```

- Les **comparaisons** impliquant un NaN sont particulières, NaN n'étant pas ordonné par rapport aux autres réels
 - $<$, $>$, $\leq$, $\geq$ et $==$ retournent toujours **false** dès qu'au moins un opérande est NaN.
 - $\neq$ retourne toujours **true**.



Les types réels en C++

- C++ supporte trois longueurs de nombres réels via les 3 types suivants
 - float simple précision
 - double double précision
 - long double précision étendue
- float et double correspondent aux formats IEEE-754 binary32 et binary64 s'ils sont supportés par l'architecture du processeur

Type et nombre de bits		Signe	Mantisse	Exposant
float	32	1	23	8
double	64	1	52	11

- long double peut utiliser 64, 80 ou 128 bits selon la mise en œuvre



numeric_limits<T> radix / is_signed / digits

- Ces infos sont disponibles via `std::numeric_limits`
- `radix` retourne la base, toujours 2 pour les types C++ prédéfinis
- `digits` retourne la précision p de la mantisse, soit le nombre de bits utilisés pour la mantisse + 1 bit implicite en représentation normalisée

```
int total = sizeof(type) * CHAR_BIT;
int base = numeric_limits<type>::radix;
int s = (int) numeric_limits<type>::is_signed;
int p = numeric_limits<type>::digits;
```

```
cout << "Base : " << base
      << "\nBits : " << total
      << "\nSigne : " << s
      << "\nMantisse: " << p-1
      << "\nExposant: " << total - (p-1) - s;
      << "\nPrécision: " << p;
```

`using type = float;`

```
Base : 2
Bits : 32
Signe : 1
Mantisse: 23
Exposant: 8
Précision: 24
```

`using type = double;`

```
Base : 2
Bits : 64
Signe : 1
Mantisse: 52
Exposant: 11
Précision: 53
```



numeric_limits<T> min() / denorm_min()

- Le **plus petit** réel strictement positif représentable avec la formule **normalisée** utilise $M = 0$ et $E = 1$, il vaut donc $r = 2^{1-B}$, soit 2^{-126} en **float** et 2^{-1022} en **double**

```
cout << "min: " << numeric_limits<type>::min() << endl;
```

float min: 1.17549e-38

double min: 2.22507e-308

- Le **plus petit** réel strictement positif représentable avec la formule **dénormalisée** utilise $M = 1$ et $E = 0$ et, il vaut donc $r = 2^{1-B-p+1}$, soit 2^{-149} en **float** et 2^{-1074} en **double**

```
cout << "denorm_min: " << numeric_limits<type>::denorm_min() << endl;
```

float denorm_min: 1.4013e-45

double denorm_min: 4.94066e-324



numeric_limits<T> lowest() / max()

- Le **plus grand réel fini** représentable utilise $m \approx 2$ et $e = E_{max} - 1 - B$, il vaut donc $r \approx 2^{E_{max}-B}$ et vaut un peu moins de 2^{128} en **float** et 2^{1024} en **double**

```
cout << "max: " << numeric_limits<type>::max() << endl;
```

float max: 3.40282e+38

double max: 1.79769e+308

- Le **plus petit réel fini** représentable utilise les mêmes m et e que le plus grand, mais le signe négatif. Il vaut donc un peu plus de -2^{128} en **float** et -2^{1024} en **double**

```
cout << "lowest: " << numeric_limits<type>::lowest() << endl;
```

float lowest: -3.40282e+38

double lowest: -1.79769e+308



numeric_limits<T>::epsilon()

- Le nombre de bits utilisés par la mantisse impacte la **précision relative** avec laquelle on peut représenter les nombres / effectuer les calculs
- On caractérise cette précision par la différence entre le plus petit réel $r > 1$ représentable dans le type utilisé ($M = 1$ et $e = 0$), et le réel 1 ($M = 0$ et $e = 0$), ce qui vaut $\epsilon = 2^{-p+1}$, soit 2^{-23} en **float** et 2^{-52} en **double**

```
cout << "epsilon: " << numeric_limits<type>::epsilon() << endl;
```

float epsilon: 1.19209e-07

double epsilon: 2.22045e-16

- Cela signifie qu'il n'y a aucun **float** dont la valeur est strictement comprise entre 1 et 1.00000011920928955078125



Egalité vs. « presque égalité »

```
bool almost_equal(double x, double y, int ulp) {  
  
    // epsilon doit être mis à l'échelle en fonction de l'amplitude  
    // des valeurs utilisées et multiplié par la précision souhaitée en ULP  
    // (unités à la dernière place)  
  
    return fabs(x - y) <= numeric_limits<double>::epsilon() * fabs(x + y) * ulp  
  
    // sauf si le résultat est un nombre dénormalisé  
  
        or std::fabs(x - y) < numeric_limits<double>::min();  
}  
  
int main() {  
    double d1 = 1. / 5.;  
    double d2 = 1. / std::sqrt(5.) / std::sqrt(5.);  
    cout << fixed << setprecision(20) << "d1=" << d1 << "\nd2=" << d2 << '\n';  
    cout << ((d1 == d2) ? "d1 == d2" : "d1 != d2") << endl;  
    cout << (almost_equal(d1, d2, 2) ? "d1 ~ d2\n" : "d1 !~ d2\n") << endl;  
}
```

```
d1=0.20000000000000000001110  
d2=0.19999999999999999998335  
d1 != d2  
d1 ~ d2
```



numeric_limits<T> digits10() / max_digits10()

- Les réels sont stockés et les calculs sont effectués en base 2
- Ils sont typiquement lus et affichés en base 10
- La conversion entre ces 2 bases n'est pas toujours sans erreur avec un nombre de chiffres limités. Par exemple, la représentation binaire du réel 0.1

IEEE 754 Converter (JavaScript), V0.22

	Sign	Exponent	Mantissa
Value:	+1	2^{-4}	1.600000023841858
Encoded as:	0	123	5033165
Binary:	☐	☐ ☒ ☒ ☒ ☒ ☐ ☒ ☒	☒ ☐ ☐ ☒ ☒ ☐ ☐ ☒ ☒ ☐ ☐ ☒ ☒ ☐ ☐ ☒ ☒ ☐ ☐ ☒ ☒ ☐ ☒ ☒ ☐ ☒ ☒

You entered

Value actually stored in float:

Error due to conversion:

Binary Representation

Hexadecimal Representation



numeric_limits<T> digits10() / max_digits10()

- `digits10()` donne le nombre maximal de chiffres décimaux significatifs pour lequel la conversion **texte** → **réel** → **texte**, i.e. la conversion décimal → binaire → décimal est toujours exacte.

```
cout << "digits10: " << numeric_limits<type>::digits10 << endl;
```

`float` `digits10: 6`

`double` `digits10: 15`

- `max_digits10()` donne le nombre minimum de chiffres décimaux significatifs nécessaires dans le texte intermédiaire pour garantir que la conversion **réel** → **texte** → **réel** soit exacte.

```
cout << "max_digits10: " << numeric_limits<type>::max_digits10 << endl;
```

`float` `max_digits10: 9`

`double` `max_digits10: 17`



Affichage d'un réel dans un flux

`<iomanip>` fournit divers modificateurs de flux dédiés à l'**affichage** de réels

- **fixed**, **scientific**, **defaultfloat**, **hexfloat** spécifient le type d'affichage
- **setprecision(n)** indique le nombre de chiffres à afficher. n vaut 6 par défaut. Le dernier chiffre est arrondi au plus proche.
- **showpoint** force l'affichage des chiffres après la virgule, même s'ils valent 0. **noshowpoint** (par défaut) l'annule.
- **showpos** / **noshowpos** (par défaut) fonctionnent comme pour les entiers
- **uppercase** / **nouppercase** (par défaut) affectent la casse du E en notation scientifique et les chiffres hexadécimaux en **hexfloat**

cout.precision() pour **cout** ou la méthode **precision()** du flux utilisé en donne la précision courante.



- Affiche tous les chiffres avant la virgule
- Affiche `cout.precision()` chiffres après la virgule
- `showpoint` / `noshowpoint` et `uppercase` / `nouppercase` n'ont pas d'effet

```
double pi = 3.1415926535897932384626433832795;  
double one_billion_billions = 1e18;  
cout << fixed << pi << " " << one_billion_billions << endl;  
cout << setprecision(15) << pi << " " << one_billion_billions << endl;  
cout << noshowpoint << pi << " " << one_billion_billions << endl;
```

```
3.141593 1000000000000000000000.000000  
3.141592653589793 1000000000000000000000.0000000000000000  
3.141592653589793 1000000000000000000000.0000000000000000
```



Affichage en scientifique

- Affiche un réel dans l'intervalle $[1,10[$ en notation fixed
- suivi de e (ou E en uppercase)
- suivi de la puissance de 10 signée par laquelle il faut multiplier le réel précédent pour obtenir le nombre à afficher
- showpoint / noshowpoint n'ont pas d'effet

```
double pi = 3.1415926535897932384626433832795;  
double billion = 1e9;  
double billionth_of_pi = pi / 1e9;  
cout << scientific;  
cout << pi << " " << billion << " " << billionth_of_pi << endl;  
cout << setprecision(3) << pi << " " << billion << " " << billionth_of_pi << endl;  
cout << uppercase << pi << " " << billion << " " << billionth_of_pi << endl;
```

```
3.141593e+00 1.000000e+09 3.141593e-09  
3.142e+00 1.000e+09 3.142e-09  
3.142E+00 1.000E+09 3.142E-09
```



Affichage en defaultfloat

- Affiche comme `scientific` pour les nombres très grands ($r \geq 10^p$ pour une précision p) ou très petits (typiquement $r < 10^{-4}$)
- Affiche comme `fixed` pour les nombres intermédiaires, mais sans les 0 finaux après la virgule.
- La gestion de la précision diffère de `fixed` et `scientific`. Ici, c'est le nombre total de chiffres significatifs qui compte, y compris avant la virgule, mais pas les zéros initiaux

```
cout << setprecision(4);  
for(double r = 3.141592e-6; r < 1e6; r *= 10)  
    cout << r << endl;
```

```
3.142e-06  
3.142e-05  
0.0003142  
0.003142  
0.03142  
0.3142  
3.142  
31.42  
314.2  
3142  
3.142e+04  
3.142e+05
```

HE^{VD} IG showpoint / noshowpoint



- En mode defaultfloat, showpoint force à toujours afficher le point décimal, suivi éventuellement de zéros si nécessaire pour atteindre la précision d'affichage voulue

```
cout << setprecision(5) << left;  
for (double r = 3.14e-6; r < 1e7; r *= 10)  
    cout << showpoint << setw(12) << r  
        << " " << noshowpoint << r << endl;
```

3.1400e-06	3.14e-06
3.1400e-05	3.14e-05
0.00031400	0.000314
0.0031400	0.00314
0.031400	0.0314
0.31400	0.314
3.1400	3.14
31.400	31.4
314.00	314
3140.0	3140
31400.	31400
3.1400e+05	3.14e+05
3.1400e+06	3.14e+06

HE^{VD} IG setprecision(n)



- Précise le nombre de chiffres décimaux à afficher
 - après la virgule en `fixed` et `scientific`
 - avant et après la virgule en `defaultfloat`, sans compter les zéros initiaux, et en n'affichant pas les zéros finaux après la virgule si `noshowpoint`
- Le dernier chiffre est arrondi au plus proche
- Des chiffres supplémentaires peuvent apparaître quand la précision demandée est plus grande que celle du type utilisé. Ils correspondent à la conversion en décimal de la représentation binaire.

```
float pi10 = 31.415926;  
cout << cout.precision() << endl  
    << scientific << pi10 << endl  
    << fixed << pi10 << endl  
    << defaultfloat << pi10 << endl  
    << setprecision(4) << pi10 << endl  
    << setprecision(30) << pi10 << endl  
    << showpoint << pi10 << endl;
```

```
6  
3.141593e+01  
31.415926  
31.4159  
31.42  
31.4159259796142578125  
31.4159259796142578125000000000
```



- Affiche la représentation en mémoire du réel $r = S \cdot 2^{E-B} \cdot (1 + \frac{M}{2^m})$
 - signe – ou + (optionnel)
 - préfixe 0x
 - La mantisse M sous la forme 1.abc avec abc la représentation hexadécimale des m bits de mantisse, avec éventuellement des bits finaux à 0 ajoutés pour obtenir le plus petit multiple de $4 \geq m$. (donc 1 pour float, 0 pour double)
 - la lettre p
 - L'exposant $E - B$ signé, affiché en décimal avec son signe toujours présent
- showpos, showpoint s'appliquent
- setprecision n'a pas d'influence



- zéro s'affiche 0x0p+0
- les nombres dénormalisés s'affichent comme s'ils étaient normaux

```
cout << hexfloat << 0.f << " " << -0.f << endl
    << 1.f << " " << -1.f << endl
    << numeric_limits<float>::denorm_min() << endl
    << numeric_limits<float>::min() << endl
    << numeric_limits<float>::lowest() << endl
    << numeric_limits<float>::max() << endl
    << numeric_limits<float>::epsilon() << endl;

for (float r = 0; r < 10; ++r)
    cout << int(r) << " " << r << endl;
```

```
0x0p+0  -0x0p+0
0x1p+0  -0x1p+0
0x1p-149
0x1p-126
-0x1.fffffep+127
0x1.fffffep+127
0x1p-23
0  0x0p+0
1  0x1p+0
2  0x1p+1
3  0x1.8p+1
4  0x1p+2
5  0x1.4p+2
6  0x1.8p+2
7  0x1.cp+2
8  0x1p+3
9  0x1.2p+3
```



Lecture d'un réel depuis un flux

- Tous les formats d'affichage précédents peuvent être lus depuis un flux d'entrée
- Les modificateurs de flux n'ont pas d'influence
- La lecture depuis un format décimal implique une conversion en format binaire. Le nombre stocké n'est donc pas toujours exactement celui entré par l'utilisateur

```
double a, b, c, d;  
stringstream in("-1.0e2 1e-2 3.141592 0x1.5p5");  
in >> a >> b >> c >> d;  
cout << a << " " << b << " " << c << " " << d << endl;  
cout << setprecision(80) << c << endl;
```

```
-100 0.01 3.14159 42  
3.141592000000000016217427400988526642322540283203125
```



- Tous les formats d'affichage peuvent être utilisés pour des constantes littérales réelles.
- Le type par défaut est `double`.
- Les suffixes `F` ou `f` (resp. `L` ou `l`) spécifient une constante littérale de type `float` (resp. `long double`)
- Attention, il est nécessaire qu'au moins un élément permette de savoir qu'il ne s'agit pas d'un entier littéral : `.` / `e` / `0x...p`
- Un réel littéral qui déborde vaut l'infini

```
auto r1 = 2.;           // double
auto r2 = 2e+1;         // double
auto r3 = -0x1.p2f;     // float
auto r4 = 3.14L;        // long double
auto r5 = 0x2p2;        // double
auto r6 = 3.1E-4L;      // long double

auto e1 = 3;            // int
auto e2 = 314L;         // long int
auto e3 = 0x2f;         // int (47)
// auto nc1 = 314F ne compile pas

auto r7 = 1e600000;     // double (inf)
auto r8 = -1e600000;    // double (-inf)
```

HE^{VD} IG Expressions mathématiques



- Comment écrire cette formule en C++ ?

$$b + \left(1 + \frac{r}{100} \right)^n$$

- La partie entre parenthèses s'écrit simplement $(1 + r / 100)$
- Mais comment écrire « à la puissance n » ?
 - C++ ne propose pas d'opérateur puissance
 - La librairie `<cmath>` propose une fonction `pow(base, exposant)`

```
#include <cmath>
using namespace std;
...
double resultat = b + pow(1 + r / 100, n);
```




`<cmath>` fournit les fonctions

- Trigonométriques
`sin, cos, tan, asin, acos, ...`
- Hyperboliques
`cosh, sinh, tanh, asinh, ...`
- Exponentielles et logarithmiques
`exp, log, ...`
- Puissances
`pow, sqrt, ...`
- Valeur absolue
`abs, fabs, ...`
- Arrondi
`round, ceil, floor, ...`
- ...

Voir <http://www.cplusplus.com/reference/cmath/>

Conversion entre types

- Syntaxe
- Types de conversions numériques
 - Promotion numérique entière
 - Conversions entier → entier, ? → réel, et réel → entier
 - Arrondis
- Conversions implicites



HE^{VD} IG Syntaxe de conversion



- Il y a 4 syntaxes qui permettent de convertir une expression d'un type à un autre. Par exemple, de int en double

```
int e = 42;
double d1 = double(e);           // forme fonctionnelle
double d2 = (double)e;           // operator de cast
double d3 = static_cast<double>(e); // static_cast
double d4 = e;                   // conversion implicite
```

- La syntaxe fonctionnelle requiert un nom de type en un seul mot. Si nécessaire, on peut utiliser un alias de type

```
using ull = unsigned long long;      unsigned long long u = ull(e);
```

- Certains guides de style recommandent de ne pas dupliquer le nom de type en utilisant le mot clé auto pour déclarer la variable initialisée par conversion

```
auto d5 = (double)e;                // d5 de type double
```



Avec 5 types entiers signés, 5 types non signés et 3 types réels, il y a 156 conversion possibles d'un type numérique à un autre. Pour simplifier, on les groupe en

- Promotions numériques vers int
- Conversions
 - Entier vers entier
 - Tout type numérique vers réel
 - Réel vers entier



Promotions numériques entières

- Conversion des types `char`, `signed char`, `unsigned char`, `signed short`, ou `unsigned short` vers `int`
 - exceptionnellement vers `unsigned int` si `int` n'est pas capable de stocker toutes les valeurs du type d'origine. Par exemple la promotion de `unsigned short` dans le modèle de donnée LP32 où `int` n'utilise que 16 bits.
- `bool` → `int` est aussi une promotion numérique. `false` vaut 0, `true` vaut 1
- Garantissent de **préserver la valeur**
- Fréquemment réalisées implicitement dans l'évaluation d'expressions arithmétiques, les opérateurs `+`, `-`, `*`, `/`, `%` n'étant pas définis pour des entiers plus courts que `int`
- Prioritaires sur les autres conversions pour l'appel de fonctions surchargées (c.f. chapitre 10)



Conversion entier $\rightarrow$ entier

- Toutes les conversions entières qui ne sont pas des promotions numériques
- La valeur est **préservée si elle est représentable** dans le type de destination
- Sinon, elle choisit la valeur dans l'intervalle représentable du type de destination sur n bits qui est **congrue modulo 2^n** avec la valeur de départ.

Note : Avant C++20, la valeur était indéfinie dans ce cas pour les types de destinations signés

```
for(int s : { 100, 200, 8100, 40000, -10 })  
    cout << setw(5) << s << " : " << setw(4) << +(unsigned char) s << "(uc) "  
        << setw(4) << +(signed char) s << "(sc) " << setw(5) << (unsigned short) s << "(us) "  
        << setw(6) << (signed short) s << "(ss)" << setw(11) << (unsigned int) s << "(ui)\n";
```

100	:	100 (uc)	100 (sc)	100 (us)	100 (ss)	100 (ui)
200	:	200 (uc)	-56 (sc)	200 (us)	200 (ss)	200 (ui)
8100	:	164 (uc)	-92 (sc)	8100 (us)	8100 (ss)	8100 (ui)
40000	:	64 (uc)	64 (sc)	40000 (us)	-25536 (ss)	40000 (ui)
-10	:	246 (uc)	-10 (sc)	65526 (us)	-10 (ss)	4294967286 (ui)



Conversions entières en complément à 2

- Avec la représentation en complément à 2, la conversion ...
 - **signed** ↔ **unsigned** ne change aucun bit
 - **long** → **court** tronque les bits de gauche
 - **court** → **long** ajoute des zéros (unsigned) ou bits de signe (signed) à gauche

```
for(int s : { 200, 40'000, 42'000'000, -10 })  
    cout << setw(8) << setfill(' ') << dec << s << " : " << hex << setfill('0')  
        << setw(8) << (signed int) s << "(si) " << setw(8) << (unsigned int) s << "(ui) "  
        << setw(4) << (signed short) s << "(ss) " << setw(4) << (unsigned short) s << "(us) "  
        << setw(16) << (signed long long) s << "(sl) " << setw(16) << (unsigned long long) s << "(ul)\n";
```

200	:	000000c8 (si)	000000c8 (ui)	00c8 (ss)	00c8 (us)	0000000000000000c8 (sl)	0000000000000000c8 (ul)
40000	:	00009c40 (si)	00009c40 (ui)	9c40 (ss)	9c40 (us)	000000000000009c40 (sl)	000000000000009c40 (ul)
42000000	:	0280de80 (si)	0280de80 (ui)	de80 (ss)	de80 (us)	000000000280de80 (sl)	000000000280de80 (ul)
-10	:	ffffff6 (si)	ffffff6 (ui)	fff6 (ss)	fff6 (us)	ffffffffffffff6 (sl)	ffffffffffffff6 (ul)



Conversions vers des réels

- La conversion de `float` en `double` est une **promotion numérique**, qui ne modifie pas la valeur. *Note : Cela n'aura pas d'incidence avant le chapitre 10*
- Pour les autres conversions vers `float`, `double` et `long double`
 - Si la valeur peut être représentée **exactement**, elle ne change pas
 - Si la valeur est comprise **entre deux valeurs représentables**, le choix entre ces deux valeurs dépend de l'implémentation.
 - Sinon, le résultat est indéfini

```
float a = 0.5;          cout << setprecision(10) << a << endl;  
float b = 3.1415926536; cout << setprecision(10) << b << endl;  
float c = 1e41;         // c est indéfini, probablement +inf
```

0.5
3.141592741



Conversion réel vers entier

- Pour convertir un réel en entier, **la partie fractionnaire est tronquée**

```
int    a = 2.55;           // a = 2
int    b = -2.55;          // b = -2
double c = 2.55;
int    d = c + 0.5;         // troncature => 3
```

- Pour une valeur **non représentable** dans le type entier, le résultat est **indéfini**

```
unsigned char a = 300;      // conversion entier → entier : a = 44

unsigned char b = 300.;     // conversion réel → entier : b indéterminé
                           // b = 0    (Apple LLVM 8.1)
                           // b = 255 (Windows gcc)

unsigned char c = int(300.); // conversion double → int → unsigned char
                           // c = 44
```

Gestion des arrondis

- La librairie `<cmath>` fournit des fonctions d'arrondi qui fournissent une **valeur entière** mais dans le **type réel** d'origine
 - `trunc` en tronquant après la virgule
 - `round` l'entier le plus proche, en s'éloignant de zéro pour .5
 - `floor` l'entier plus petit ou égal
 - `ceil` l'entier plus grand ou égal
- Les mêmes fonctions finissant par `f` ou `l` convertissent en `float` ou `long double`
 - `truncf`, `floorf`, `roundf`, `ceilf`
 - `truncl`, `floorl`, `roundl`, `ceil`

value	trunc	round	floor	ceil

2.3	2.0	2.0	2.0	3.0
3.8	3.0	4.0	3.0	4.0
5.5	5.0	6.0	5.0	6.0
-2.3	-2.0	-2.0	-3.0	-2.0
-3.8	-3.0	-4.0	-4.0	-3.0
-5.5	-5.0	-6.0	-6.0	-5.0



Attention aux erreurs d'arrondi

- La conversion réel → entier pour donner des résultats surprenants

```
double d = 100 * 4.35;  
cout << d << " ?= " << int(d) << endl;
```

435 ?= 434

- Le calcul en réel se fait avec une précision finie en sa représentation binaire. Le résultat n'est pas exactement 435

```
cout << setprecision(20) << d << endl;
```

434.9999999999999994316

- On résout ce problème en spécifiant explicitement la méthode d'arrondi avant de convertir en entier

```
cout << int(round(d)) << endl;
```

435

HE^{VD} IG Conversions implicites



- Il est possible d'écrire des expressions arithmétiques en mélangeant les types. Par exemple,


```
auto x = 5 * 3.14F + 5.3e-2;
```

- Pourtant, les opérateurs arithmétiques binaires
 - ne sont définis que pour deux **opérandes de même type**
 - **retournent** une valeur du **même type** que leurs opérandes
- Les opérateurs (unaires ou binaires) ne sont **pas définis** pour les types entiers plus courts que `int` (`signed char`, `unsigned char`, `signed short` et `unsigned short`)
- Il y a donc **conversion implicite des opérandes** avant d'appliquer l'opérateur

HE^{VD} IG Example



```
auto x = 5 * 3.14F + 5.3e-2;
```





Conversion arithmétique

- L'évaluation de l'expression se fait selon l'**ordre défini par les priorités** des opérateurs
 1. Unaire (+, -)
 2. Multiplicatif (*, /, %)
 3. Additif (+, -)
- **Pour les opérateurs unaires**, on applique si nécessaire la promotion numérique entière
 - Les expressions `+a` et `-a` sont de type `int` si `a` est de type `char` ou `short`, signé ou pas

```
unsigned char a = 65;
```

```
unsigned short b = 1;
```

```
unsigned int c = 1;
```

```
cout << a << " " << +a << " " << -a << " " << -b << " " << -c << endl;
```

A	65	-65	-1	4294967295
---	----	-----	----	------------



Pour les opérateurs binaires

- On applique la **promotion numérique entière** aux types `char` ou `short`, signés ou pas
- Si un opérande est de type `long double`, on convertit l'autre en `long double`
- Sinon, si un opérande est de type `double`, on convertit l'autre en `double`
- Sinon, si un opérande est de type `float`, on convertit l'autre en `float`
- Sinon, la conversion est entre deux types entiers. Elle dépend
 - des signes (`signed` → `unsigned`)
 - des rangs (`int` → `long` → `long long`)



Conversion arithmétique entre entiers

- Quand le type d'un des opérandes est meilleur ou égal à l'autre du point de vue du **signe** et de la **longueur**, l'autre est converti dans ce type

int, long	-> long
int, long long	-> long long
int, unsigned int	-> unsigned int
int, unsigned long	-> unsigned long
int, unsigned long long	-> unsigned long long
long, long long	-> long long
long, unsigned long	-> unsigned long
long, unsigned long long	-> unsigned long long
long long, unsigned long long	-> unsigned long long
unsigned int, unsigned long	-> unsigned long
unsigned int, unsigned long long	-> unsigned long long
unsigned long, unsigned long long	-> unsigned long long



Conversion arithmétique entre entiers (2)

- Quand un type est meilleur que l'autre selon un critère et vice-versa pour l'autre, i.e. pour les 3 paires de types suivantes

```
unsigned int , long  
unsigned int , long long  
unsigned long, long long
```

- La conversion **dépend du modèle de donnée**, i.e. du nombre de bits utilisés pour représenter chaque type
 - Si l'opérande signé peut représenter toutes les valeurs de l'opérande non signé, l'opérande non signé est converti dans le type signé.
 - Sinon, les deux opérandes sont convertis dans la version non signée du type signé



Conversion arithmétique entre entiers (3)

- En pratique, si `int` et `long` utilisent 32 bits et `long long` 64 (LLP64 sur Windows API)

```
unsigned int , long      -> unsigned long
unsigned int , long long -> long long
unsigned long, long long -> long long
```

- Par contre, si `int` utilise 32 bits, `long` et `long long` 64 (LP64 sur Linux ou Mac OS X)

```
unsigned int , long      -> long
unsigned int , long long -> long long
unsigned long, long long -> unsigned long long
```

- Et donc, l'exécution du code suivant dépend de l'OS

```
unsigned int a = 1; long b = 2;
unsigned long c = 1; long long d = 2;
cout << a - b << " " << c - d << endl;
```

-1 18446744073709551615



4294967295 -1





Attention aux comparaisons

- Les règles pour les opérateurs arithmétiques s'appliquent également aux opérateurs de comparaison
- Cela pose problème si l'on compare des entiers signés et non signés

```
signed int    a = -1;  
unsigned int  b =  1;  
  
cout << boolalpha;  
  
cout << (signed(-1)    < signed(1))    << endl;  
  
cout << (unsigned(-1) < unsigned(1)) << endl;  
  
cout << (a < b) << endl;
```

true

false

false



Avertissements du compilateur

- Le compilateur peut nous avertir de ces conversions implicites dégradantes (perte de précision / dépassement possible) avec l'option **-Wconversion**

```
int unEntier = 3.14;
```

```
warning: implicit conversion from  
'double' to 'int' changes value from  
3.14 to 3 [-Wliteral-conversion]
```

- Le compilateur peut nous en avertir de conversions implicites entre types signés et non signés avec l'option **-Wsign-conversion**

```
int a = 4;  
unsigned int b = 5;  
cout << a - b; // affiche 4294967295
```

```
warning: implicit conversion  
changes signedness: 'int' to  
'unsigned int' [-Wsign-conversion]
```



Au delà du C++, quel que soit le langage ...

- Quels types sont disponibles pour traiter des entiers / des réels ?
- Quel est leur coût en mémoire ?
- La langage dispose-t-il d'un type non signé ?
- Quelle est la plage des valeurs représentables par chaque type ?
- Quelle est la précision des calculs en réel ?
- Comment le dépassement est-il géré lors des calculs ?
- Quels opérateurs / fonctions mathématiques sont disponibles ?
- Comment convertir explicitement d'un type à l'autre ?
- Comment les conversions implicites sont-elles gérées dans les expressions hybrides (si elles sont autorisées) ?
- Comment les arrondis sont-ils gérés ?
- Comment formater ces nombres sous forme de texte ?
- Existe-t-il un type réel en base décimale pour les calculs financiers ?